

Relatório Global Solution (GS) - O Futuro do Trabalho

Sistema de Análise de Risco de Esgotamento (*Burnout*) em Equipes

Tema: Ferramentas de monitoramento de bem-estar e saúde mental no trabalho.

Solução Proposta: Sistema preditivo de risco de Burnout.

Grupo 29

Nomes dos Integrantes e RM:

- Leticia Angelim Guerra - RM567501
- Rivando Bezerra Cavalcanti Neto - RM568235
- Tales Ferraz de Arruda Domienikan - RM567483
- Matheus Guimarães França - RM567144
- João Rafael Gonçalves Ramos - RM567908

LINKS:

1. **Vídeo:** <https://youtu.be/YGQn7Z8VAk0>
2. **Repositório GitHub:** <https://github.com/matquifra/global-solutions-2025.2>
3. **Jupyter Notebook no Google Colab:**
https://colab.research.google.com/drive/1XYr_AHWSrffEgmHLFQMhXqFwFFN-u4KV

1. Introdução

O futuro do trabalho impõe desafios que transcendem a produtividade e tocam diretamente no bem-estar humano. Com a automação e a hiperconectividade, o risco de Esgotamento Profissional (Burnout) se intensifica. Diante do desafio "Como a tecnologia pode tornar o trabalho mais humano, inclusivo e sustentável no futuro?", nossa Prova de Conceito (POC) propõe o **Sistema de Análise de Risco de Esgotamento (Burnout) em Equipes**.

Este sistema utiliza dados operacionais para prever, com antecedência, quais membros da equipe estão sob maior risco de desenvolver Burnout, permitindo que o RH e os líderes intervenham proativamente com suporte e ajuste de carga de trabalho. Este relatório detalha a arquitetura, a implementação mínima viável (MVP) e a aplicação dos conhecimentos adquiridos nas disciplinas do curso.

2. Desenvolvimento da Solução (*Proof of Concept*)

A solução é um POC que demonstra a viabilidade técnica de um sistema preditivo, dividido em três componentes principais: Coleta / Armazenamento de Dados, Processamento / Previsão (ML) e Visualização.

2.1. Estrutura e Arquitetura da Solução (Matheus)

A solução será implementada em um *Jupyter Notebook* feito no Google Colab. O Google Colab é um serviço de hospedagem em nuvem elástico, ou seja, tem capacidade de armazenagem e processamento expansíveis, de *notebooks Jupyter*.

O notebook se estrutura desta forma:

- Dados:
 - Importação
 - Importação do csv
 - Criação do DataFrame
 - Tratamento
 - Criação de variáveis para exploração
 - Exclusão de variáveis ruins ou irrelevantes
 - Exploração
 - Distribuições das variáveis
 - Comparação das variáveis para cada *label*
 - Investigação de anomalias
 - Matriz de correlação
 - Verificar variáveis redundantes
 - Identificar variáveis mais influentes para o *label*

- Matriz de *scatterplots*
 - Confirmar grau de influência das variáveis para o *label*
 - Verificar se há linearidade ou não entre as variáveis independentes
- Modelagem:
 - *Feature Engineering*
 - *Encoding* e normalização das variáveis
 - Divisão do *dataset* em treino e teste
 - Produção dos modelos
 - Regressão Logística
 - *K Nearest Neighbors*
 - *Support Vector Machine*
 - Linear
 - Polinomial
 - RBF
 - Árvore de Decisão
 - Floresta Aleatória
 - Predições
- Visualização
 - Performance
 - Acurácia
 - Precisão
 - Recall
 - f1 score
 - Matriz de confusão (por *recall*)
- Conclusão
 - Comparação das performances
 - Confirmação de hipóteses
 - Observações

2.2. Base de Dados

```
1  senioridade,idade,horas_trabalho,pct_reunioes,interacoes_noturnas,periodo_sem_ferias,score_satisfacao,burnout_label
2  Junior,25,48,0.44,5,12,5,0
3  Junior,20,41,0.48,2,7,4,0
4  Senior,31,47,0.24,7,26,5,0
5  Junior,36,47,0.53,3,14,3,0
6  Junior,31,44,0.27,1,7,3,0
7  Pleno,30,43,0.1,5,36,1,0
8  Pleno,39,42,0.35,4,3,4,0
9  Junior,29,45,0.22,4,2,5,0
10 Junior,26,41,0.34,5,14,3,0
11 Pleno,33,49,0.53,6,7,3,1
12 Pleno,35,52,0.32,7,6,2,1
13 Junior,30,40,0.25,4,2,5,0
14 Pleno,33,43,0.31,7,13,3,0
15 Senior,27,50,0.28,2,4,2,0
16 Senior,27,46,0.12,2,5,4,0
17 Pleno,25,52,0.49,3,1,4,0
18 Senior,33,48,0.45,9,11,5,1
19 Pleno,20,48,0.57,3,9,5,0
20 Pleno,27,50,0.47,5,4,5,0
21 Junior,21,42,0.53,4,2,2,0
22 Pleno,31,35,0.11,2,7,1,0
23 Pleno,31,45,0.32,4,4,5,0
24 Pleno,27,41,0.31,1,7,1,0
25 Pleno,26,45,0.13,10,8,5,0
```

2.2.1 Geração dos Dados Sintéticos

Para criar *dataset* com 5.000 funcionários, usamos Python com as bibliotecas NumPy e Pandas. A ideia foi gerar números aleatórios que pareçam reais, mas sem dados pessoais de verdade.

Para cada coluna da tabela, sorteamos valores seguindo um padrão que faz sentido no dia a dia:

- **Senioridade:** $\approx 40\%$ Júnior, $\approx 40\%$ Pleno, $\approx 20\%$ Sênior.
- **Idade:** valores em torno de 30 anos, entre 20 e 60.
- **Horas trabalhadas por semana:** varia conforme a senioridade (Júnior $\approx 42h$, Pleno $\approx 45h$, Sênior $\approx 48h$).
- **Percentual de tempo em reuniões:** entre 10% e 60% do expediente.
- **Interações noturnas:** mensagens de texto / e-mail fora de expediente, em média 5 por semana.
- **Meses sem férias:** entre 0 e 36 meses, geralmente concentrado entre 6 e 12 meses.
- **Satisfação:** escala de 1 a 5 distribuída aleatoriamente.

2.2.2 Cálculo do Risco de Burnout

Depois calculamos o "Risco de Burnout" somando fatores que aumentam estresse (horas trabalhadas em excesso, mensagens noturnas, tempo sem férias, muitas reuniões) e subtraindo a satisfação.

O resultado foi marcar 30 % dos funcionários como "Alto Risco". Essa porcentagem é baseada em dados reais da Anamt.

2.2.3 Como seria a coleta em uma empresa real:

Cada informação que precisamos vem de um sistema diferente da empresa:

1. Sistema de RH / Banco de Dados de Funcionários

Guarda informações sobre admissão, férias, licenças, senioridade e dados pessoais dos colaboradores. Dele extraímos:

- **Senioridade** (Júnior, Pleno, Sênior).
- **Idade do funcionário**
- **Período sem férias** (data da última saída e se ainda está afastado)

2. Calendário Corporativo (Google Calendar / Outlook)

Onde ficam registradas todas as reuniões. Somamos o tempo total em reuniões e calculamos qual % do expediente foi gasto.

3. Aplicativos de Mensagens (WhatsApp Business, Teams, Outlook)

Plataformas onde os colaboradores trocam mensagens dentro da empresa. Contamos quantas mensagens foram enviadas fora do horário (depois das 19h, antes das 8h, nos fins de semana).

4. Pesquisa de Clima / Satisfação

Formulário enviado periodicamente perguntando como o funcionário está se sentindo. Respostas em escala 1 a 5.

5. Dados de Ponto / Jornada

Sistema onde fica registrado o horário de trabalho, fornecendo a jornada total da semana.

2.3. Privacidade, Segurança e Arquitetura de Acesso

O sistema foi projetado de forma a garantir que o uso das informações dos usuários no ambiente corporativo seja compatível com os princípios da LGPD, ao mesmo tempo em que adota boas práticas de segurança da informação.

2.3.1 Coleta e Minimização

A coleta de dados segue o princípio da minimização, utilizando apenas variáveis relevantes para o risco de burnout (como jornada, reuniões, interações fora do expediente, férias e satisfação).

2.3.2 Anonimização e Tratamento

Antes de qualquer processamento, os dados são **anonimizados** utilizando identificadores aleatórios (UUIDs ou hashes), impedindo que o modelo ou os analistas tenham acesso a informações identificáveis.

2.3.3 Segurança do Ambiente

O repositório utilizado durante a prova de conceito é privado no GitHub, com controle individual de acesso. No ambiente real, o sistema adotará camadas de segurança baseadas em:

- **Criptografia em trânsito (HTTPS/TLS)** para proteger os dados enquanto trafegam entre o painel e a API.
- **Criptografia nos dados** para garantir que os dados armazenados no banco permaneçam ilegíveis sem chave de acesso.
- **RBAC (Role-Based Access Control)** no painel de RH, garantindo que apenas usuários autorizados visualizem as informações conforme sua função.
- **Logs de auditoria**, registrando todas as ações sensíveis para rastreamento e conformidade.
- **Políticas de retenção e descarte seguro de dados**, evitando armazenamento excessivo ou indevido.

2.3.4 Arquitetura do Painel de RH e Controle de Acesso


O painel de visualização será desenvolvido como uma aplicação web segura, com autenticação obrigatória e acesso restrito. A arquitetura proposta é:

- **Interface (Frontend):** Vue.js, Nuxt.js ou Streamlit para visualização dos resultados
- **API Segura:** FastAPI ou Flask para servir o modelo e controlar as requisições

- **Banco de Dados:** PostgreSQL com registros anonimizados
- **Modelo:** Treinado offline e carregado de forma isolada pela API

2.3.5 Prévia do Dashboard de Risco de Burnout com dados anonimizados

A imagem abaixo ilustra como o painel de RH poderá visualizar os resultados do modelo preditivo, exibindo apenas dados anonimizados e indicadores de risco, seguindo os princípios de privacidade e segurança definidos pelo sistema:



Toda comunicação entre o painel e o backend acontece de forma criptografada. O RBAC garante que:

Papel	Acesso aos dados
RH autorizado	Pode ver risco de burnout, sem dados pessoais
Gestores	Apenas sua própria equipe
Analistas / TI	Apenas dados anonimizados
Funcionários comuns	Nenhum acesso

Essa arquitetura garante que apenas usuários autorizados visualizem informações sensíveis, mantendo rastreabilidade e conformidade com a LGPD.

2.3.6 Segurança aplicada ao modelo preditivo

Mesmo o modelo de Machine Learning sendo treinado com dados anonimizados, sua execução também é protegida. O modelo não será acessado diretamente, ele será exposto apenas através de uma API autenticada com autorização por função, impedindo acesso indevido ao arquivo do modelo ou às previsões.


O sistema pode ainda registrar logs de uso e validar as entradas para evitar ataques e inferências reversas, garantindo que a inteligência artificial opere de forma segura e alinhada à LGPD.

2.4. Análise Exploratória

Depois dos dados serem importados de um `csv` armazenado em nuvem, é criado um `DataFrame` Pandas, as variáveis são explicadas e a exploração dos dados é iniciada.

2.4.1 Frequência relativa da variável alvo

Primeiro vemos a frequência que nossa variável alvo tem no `dataset` a fim de nos assegurarmos de que a métrica de acurácia terá relevância.




A incidência de *burnout* foi de 30,02% (69,98% sem *burnout*).

Vemos que o *dataset* é desbalanceado, ou seja, a acurácia será uma métrica de segundo plano.

2.4.2 Distribuição das variáveis independentes

Prosseguimos com a visualização das distribuições das variáveis independentes por categoria alvo (com *burnout* e sem *burnout*) a fim de se ter uma noção inicial de quais variáveis são influentes no problema em questão (e qual grau de influência) e quais são irrelevantes.


Começamos pela única variável independente categórica: senioridade.



A ocorrência de *burnout* aumenta com a senioridade, de cerca de 5 pontos percentuais de Júnior para Pleno e de cerca de 10 de Pleno para Sênior.

Uma hipótese seria o aumento de responsabilidades.


Agora, as variáveis numéricas:



Podemos ver que a idade parece irrelevante para o problema.

Todas outras variáveis parecem ter influência no problema, com o *score* de satisfação sendo aparentemente o mais gritante — 50% dos que tiveram *burnout* deram nota 3 ou menos para satisfação com o clima da empresa, com a nota mais frequente sendo 2, já a nota mais frequente dos que não tiveram *burnout* foi 4, o dobro.

Percebemos que, aparentemente, a jornada de trabalho não é tão influente como a intuição nos diz. Podemos fazer uma análise de como as horas de trabalho que excedem as 40h semanais impactam. Criamos então uma variável nova que representa as horas extras subtraindo 40 da variável jornada de trabalho com um piso de 0 nos valores (não faz sentido hora extra negativa, e mesmo que fizesse sentido a nova variável seria um mero deslocamento da original).



Vemos que há de fato uma relação de horas extra com incidência de *burnout*, mas o resultado não tem diferença significativa com a análise anterior da jornada de trabalho total.

Isso pode se dever ao fato de que ou a grande maioria não faz hora extra ou a grande maioria faz hora extra, de forma que os dois conjuntos de dados seriam quase os mesmos.


Fazendo uma contagem do número de ocorrências de 0 horas extra, ou seja, quantas pessoas não fazem horas extras: o resultado é de 17,06%. Ou seja, muito

pequeno, confirmando a hipótese de que a variável jornada de trabalho e a variável horas extra são praticamente as mesmas. Vamos então descartá-la e prosseguir.

2.4.3 Matriz de correlação para identificar variáveis redundantes

Agora verificamos se duas ou mais variáveis se correlacionam muito a fim de podermos descartar uma delas por serem redundantes. Por exemplo, se duas variáveis têm uma correlação superior a 90%, elas praticamente carregam a mesma informação.

Além disso, quando colocamos a variável alvo na matriz, é possível aferir o grau de impacto que cada variável tem no alvo.




Podemos fazer algumas conclusões:

- A idade é realmente irrelevante.
- A senioridade não é nem um pouco relevante quanto imaginamos pelo gráfico de *burnout* por senioridade, tendo correlação mínima (10%)
- Jornada de trabalho, atividade fora do expediente e a nota de satisfação do funcionário são as variáveis decisivas.

2.4.4 Verificação de linearidade

Agora, vamos verificar se as variáveis são lineares entre si ou não. Isso nos dará uma pista de que classe de modelos serão os melhores. Se houver linearidade, modelos como Regressão Logística ou SVM linear serão ótimos, caso contrário, modelos de árvores

ou SVM polinomial ou RBF serão melhores. Faremos uma matriz de *scatterplots* sem idade e senioridade a fim de descongestionar o gráfico e acelerar sua produção, respaldados pelo fato de serem variáveis irrelevantes ou fracas:



Podemos ver clara linearidade entre as variáveis: uma clara linha reta separa os dados em alguns plots.

Vemos também que algumas variáveis não têm relação entre si, tendo seus pontos quase homogeneamente espalhados.

Aqui confirmamos ainda mais a força do score de satisfação no problema: há uma clara separação na curva se distribuição com *burnout* e sem.

2.5. Modelagem Preditiva

O coração da solução é o modelo preditivo que classifica o risco do colaborador colapsar por esgotamento — o *burnout*.

Trabalharemos com 7 modelos de classificação binária:

- Regressão Logística
- *K nearest neighbors*
- *Support Vector Machine*
 - Linear
 - Polinomial
 - RBF
- Árvore de Decisão
- Floresta Aleatória

2.5.1 Feature engineering

2.5.1.1 Encoding

Primeiro, faremos o *encoding* (codificação) da única variável categórica: a senioridade. Fazemos um simples mapeamento de números inteiros com as categorias: 0 para Junior, 1 para Pleno, 2 para Sênior.

Isso é possível devido a natureza ordinal da variável: há importância (Júnior < Pleno < Sênior), direção (Junior vira Pleno, Pleno vira Sênior) e distância (Sênior está mais distante de Junior do que do Pleno).

Agora que todas as variáveis são numéricas, vamos para a divisão de treino e teste.

2.5.1.2 Separação treino / teste

Antes da separação treino e teste, definimos a matriz *X* que contém as variáveis independentes e o vetor *y* que tem a variável dependente.

Feito isso, separamos a matriz de variáveis e o vetor de alvo em dois conjuntos, um de treino e um de teste, na razão de 70% treino (30% teste), preservando o *seed* de aleatoriedade com o número 42.


2.5.1.3 Normalização

Antes do início do treinamento, é necessário ajustar todas as variáveis independentes para a mesma escala.

Se isso não for feito, os modelos pensarão que a variável de jornada de trabalho é mais importante que a idade por ter valores maiores (a maioria das jornadas tem mais de 40 e maioria das idades estão ao redor de 30), e a idade mais importante que as notas dos funcionários (vão de 1 a 5).

Para isso usamos o StandardScaler, que transforma um conjunto de dados, coluna a coluna, para que tenham média 0 e desvio padrão 1.

Feita a normalização, partimos para a produção dos modelos.



2.5.2 Modelagem

A produção dos modelos é trivial:

1. Cria-se os objetos que armazenam os modelo por meio da chamada dos construtores de classe:

```
log_reg = LogisticRegression()
```

2. Treina-se o modelo com *fit()* passando os *datasets* de treinamento como parâmetros (*X_train_scaled*, *y_train*):

```
log_reg.fit(X_train_scaled, y_train)
```


3. Gera-se as previsões com *predict()* passando o *dataset* de teste como parâmetro para gerar o conjunto de previsão para avaliar a performance comparando com o conjunto real:

```
y_pred_log_reg = log_reg.predict(X_test_scaled)
```


2.6. Visualização dos Dados

2.6.1 Matrizes de confusão


Iniciaremos a comparação dos resultados examinando as matrizes de confusão de cada um dos sete modelos:




Regressão Logística: Este foi o modelo de melhor desempenho, apresentando uma taxa de Falsos Negativos de apenas **0,45%**. Isso significa que o modelo identificou corretamente quase a totalidade dos colaboradores com risco de Burnout. Também valida a hipótese de linearidade dos dados.




K Nearest Neighbors: O modelo apresentou um desempenho inferior aos lineares, com uma taxa de Falsos Negativos de **5,6%**. Embora tenha uma boa acurácia geral, ele falhou em identificar uma parcela significativa dos funcionários em risco.




SVM Linear: Com resultados muito próximos à Regressão Logística, este modelo obteve uma taxa de acerto de **99%** na classe de Burnout (Falsos Negativos de 0,67%). Isso reforça que a separação entre colaboradores saudáveis e em risco segue um padrão linear claro.




SVM Polinomial: A adição de complexidade polinomial não beneficiou a predição. O modelo teve uma queda de performance, errando **6,9%** dos casos positivos (Burnout), provando ser menos eficaz que sua versão linear para este conjunto de dados.



SVM RBF: O kernel RBF apresentou alta performance, errando apenas **1,3%** dos casos de Burnout. No entanto, por ser computacionalmente mais pesado, não se justifica como primeira escolha.




Árvore de Decisão: Este modelo apresentou o **pior desempenho** entre os testados para a detecção de risco, com uma taxa de Falsos Negativos de **7,2%**. Sua instabilidade e tendência a errar classificações críticas o tornam inadequado para este MVP.



Floresta Aleatória: O uso de múltiplas árvores melhorou o resultado em comparação à Árvore de Decisão única, reduzindo os erros para **4,7%**. Contudo, ainda ficou abaixo da performance obtida pelos modelos lineares mais simples.

2.6.2 Comparação das métricas



O gráfico consolida a superioridade da **Regressão Logística** e do **SVM Linear**, que atingiram os maiores índices de *Recall* (barra verde) e F1-Score (barra vermelha). Nota-se que modelos não lineares (como **Árvore de Decisão**) tiveram dificuldades em capturar o padrão dos dados com a mesma precisão.

3. Resultados

O MVP, apesar de simples, atingiu os seguintes resultados:

Modelo	Recall
Regressão Logística	99,55%
SVM Linear	99,33%
SVM RBF	98,66%
Floresta Aleatória	95,30%
KNN	94,41%
SVM Polinomial	93,06%
Árvore de Decisão	92,84%

Todos os modelos apresentaram métricas altas (acurácia, precisão, recall e F1), indicando ótimo desempenho geral.

Devido à natureza do problema em questão (identificar pessoas com risco de terem um problema de saúde — burnout) o recall é de longe a métrica mais importante: é muito mais impactante não abordar uma pessoa prestes a ter um burnout do que abordar alguém que está bem. Se o RH não abordar uma pessoa prestes a ter um burnout, além do prejuízo à saúde do funcionário, a empresa perde esse funcionário até a sua recuperação, enquanto abordar um funcionário que está bem é só um mal entendido.

- **Validação Técnica:** Demonstrou que um sistema preditivo de esgotamento de funcionários a partir da base de dados do RH e outras ferramentas de trabalho é absolutamente viável e possível.
 - **Impacto no Bem-Estar:** Com uma taxa de acerto (*recall*) de 99,55% na classificação de risco (usando dados simulados), o sistema é capaz de identificar colaboradores em potencial perigo, transformando dados brutos em ações preventivas de RH.
 - **Entrega Completa:** O grupo conseguiu aplicar e documentar o conteúdo de todas as disciplinas exigidas para a nota.
-

4. Conclusões


A Global Solution foi uma oportunidade de integrar teoria e prática. A criação do MVP comprovou que a tecnologia, quando guiada por princípios éticos, pode atuar como um agente de humanização no trabalho.

A justificativa social do projeto reside na promoção de um ambiente de trabalho mais humano e inclusivo. O sistema foca no apoio e na prevenção, e não na punição. Isso garante que a tecnologia seja uma aliada do bem-estar, e não uma ferramenta de controle. Nossa solução endereça a sustentabilidade humana, que é tão vital quanto a sustentabilidade ambiental.

Do ponto de vista técnico, a metodologia se mostrou robusta. Através da Análise Exploratória dos Dados e da modelagem preditiva em Python, demonstramos que o modelo de Regressão Logística é altamente eficaz, validando a hipótese de que o risco de Burnout tem uma natureza linear.

Importante ressaltar que um dataset real pode ter variáveis não lineares, mas nada vai mudar no pipeline deste sistema preditivo, apenas as performances dos modelos vão

ser outras e o novo melhor modelo vai poder ser identificado no fim, na parte de visualização dos resultados.



E considerando que este sistema é um Proof of Concept, ou seja, uma base que prova que o conceito — prever burnout iminente — é válido e possível, quando for colocado em produção precisará antes de alguns ajustes finos, como a definição do threshold ótimo do conjunto de probabilidades da previsão por meio de análise do gráfico de precisão vs recall, por exemplo, depois de treinar em um dataset real.

A distribuição de tarefas garantiu que todos os membros do grupo contribuíssem com suas áreas de especialidade, resultando em um projeto coeso e completo.